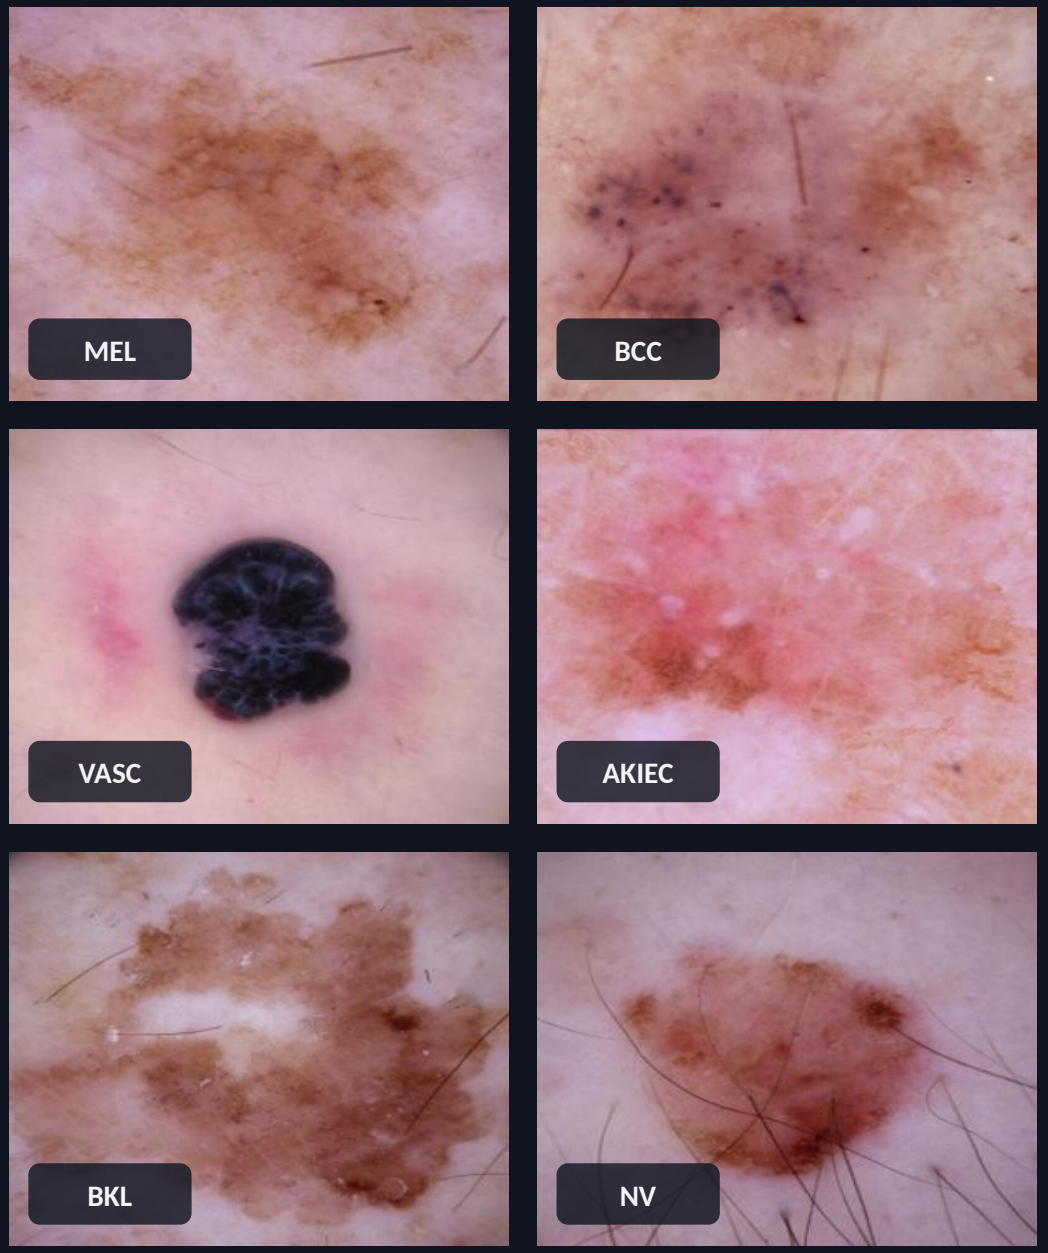
PROJETO FINAL • TEMA 3 • ENTREGA FINAL

Classificação de lesões de pele com redes neurais

ResNet-18 com transferência de aprendizado em 7 categorias do ISIC 2018 — baseline, dois experimentos controlados e análise de erros.

Valmir Carlos Cerutti Neto
Ciência de Dados e IA — IBMEC-BH
Visão Computacional e Redes Neurais • 2º sem. 2026 • 12/11/2026



Lesões de pele: muitas classes, poucas imagens das mais graves

CONTEXTO

- A dermatoscopia gera imagens ampliadas e padronizadas da pele; um classificador automático pode ajudar a priorizar lesões suspeitas.
- O desafio é o desbalanceamento: nevos benignos (NV) são 67% das imagens; dermatofibroma (DF) é 1,1%.
- Errar um melanoma (MEL) custa mais que errar um nevo — por isso a revocação de MEL é acompanhada à parte.

PERGUNTA DO PROJETO

Quando o modelo acerta, quando erra e se ele sabe que está errando?

Pergunta definida na M1 (18/09). Para respondê-la: um baseline e dois experimentos controlados escolhem o melhor classificador; depois, a análise de erros e a análise de confiança desse modelo respondem às três partes.

11.527

imagens rotuladas (ISIC 2018 Task 3 + teste oficial)

7

classes diagnósticas

58×

razão entre a maior (NV) e a menor classe (DF)

53%

dos rótulos confirmados por biópsia — o resto é consenso ou acompanhamento

Escopo ajustado ao enunciado final: só classificação; a segmentação e o Grad-CAM previstos na M1 ficaram como evolução. Sistema educacional — não substitui avaliação clínica.

2 • TAREFA DE VISÃO COMPUTACIONAL

Classificação multiclasse: uma imagem entra, uma de 7 classes sai

Imagem
RGB dermatoscópica
[3 × 224 × 224]

→

ResNet-18
rede convolucional
11,2 M parâmetros

→

7 logits
um valor por classe
[7]

→

Softmax
probabilidades
que somam 1

→

Resultado
classe mais provável
+ probabilidades

AS 7 CLASSES (IMAGENS NO ISIC 2018 TASK 3)

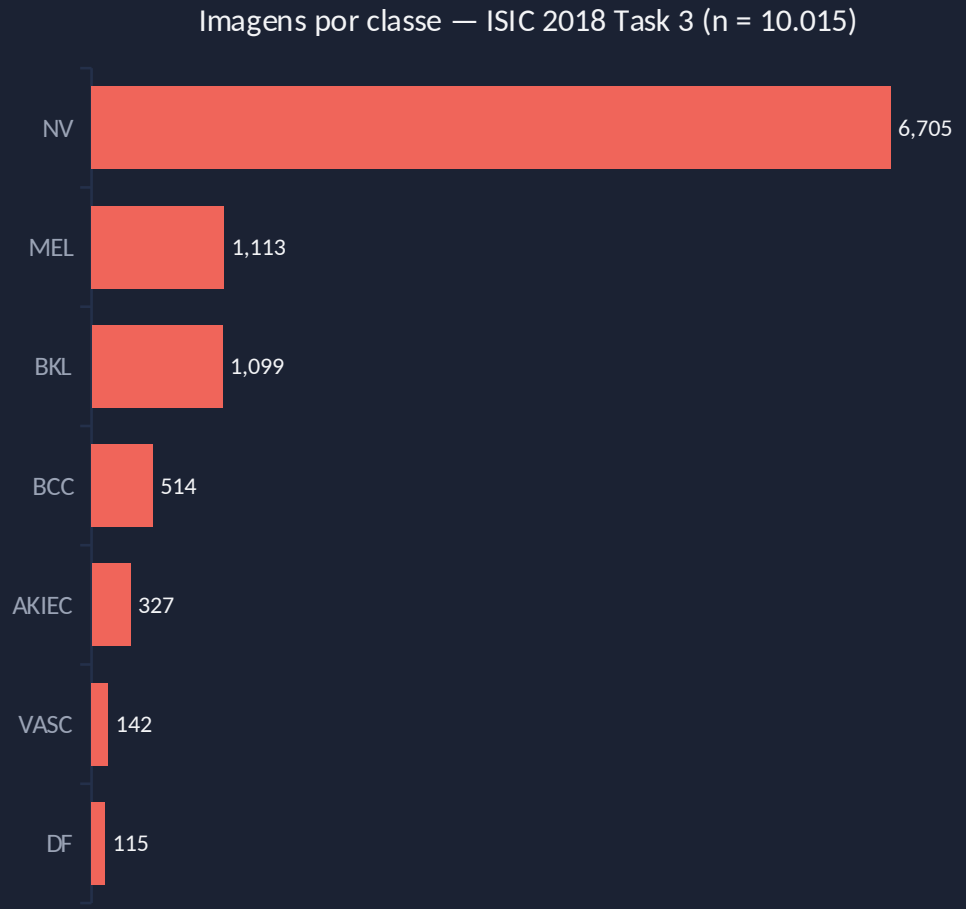
MEL 1.113 melanoma	**NV** 6.705 nevo melanocítico	**BCC** 514 carcinoma basocelular	**AKIEC** 327 queratose actínica / Bowen
BKL 1.099 lesão queratósica benigna	**DF** 115 dermatofibroma	**VASC** 142 lesão vascular	

■ maligna/pré-maligna ■ benigna

COMO MEDIMOS

- **Macro-F1** (principal): média simples do F1 das 7 classes — NV não domina a nota.
- **Acurácia e acurácia balanceada** (média das revocações).
- **Precisão, revocação e F1 por classe** e matriz de confusão.
- **Revocação de MEL** acompanhada à parte (classe prioritária).
- **Confiança:** AUROC e acurácia por limiar — o modelo sabe quando erra?

ISIC 2018: divisão 70/15/15 por lesão, mais um teste externo



Conjunto	Imagens	Uso
Treino	7.017 (70%)	ajuste dos pesos
Validação	1.487 (15%)	escolha da época e do modelo
Teste interno	1.511 (15%)	avaliação final (uma vez)
Teste oficial ISIC	1.512	holdout externo (uma vez)

CUIDADOS CONTRA VAZAMENTO DE DADOS

- **Divisão agrupada por lesion_id** (StratifiedGroupKFold, seed 42): 1.956 lesões têm 2–6 fotos; 0 lesões em mais de um conjunto.
- **Duplicatas:** MD5 + pHash + inspeção visual — 0 duplicatas confirmadas entre conjuntos.
- **Estratificada por classe:** MEL ≈ 11% em treino, validação e teste.
- **Testes bloqueados:** teste interno e oficial só avaliados com o modelo final já escolhido.

4 • PIPELINE DE PREPARAÇÃO

A mesma preparação no treino, na avaliação e na demonstração

1 Leitura

JPG 600×450, convertido para RGB

2 Redimensionamento

lado menor → 256 px (341×256), uma única vez, INTER_AREA

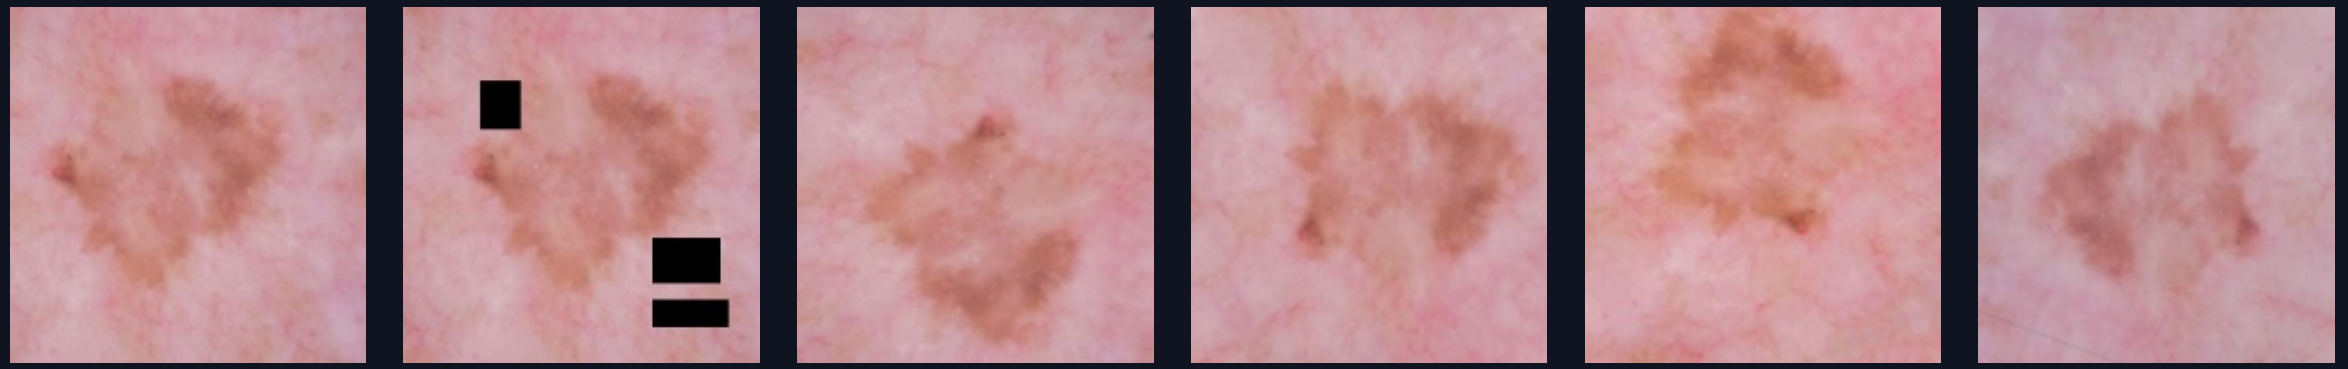
3 Recorte 224×224

treino: recorte aleatório + aumento de dados
avaliação: recorte central, sem sorteio

4 Normalização

média e desvio do ImageNet — nenhuma estatística calculada nos dados

AUMENTO DE DADOS — SÓ NO TREINO (MESMA IMAGEM BKL, 6 SORTEIOS)



Transformações: recorte aleatório (70–100% da área), flips horizontal e vertical, rotação até 180° (lesão não tem orientação), variação leve de cor (cor é sinal diagnóstico), e CoarseDropout p = 0,3 — apaga blocos para a rede não depender de cantos escuros (vinheta), associados a MEL na auditoria.

Baseline: ResNet-18 pré-treinada no ImageNet, ajustada por inteiro

Entrada	3 × 224 × 224
Conv 7×7 + MaxPool	64 × 56 × 56
4 estágios residuais	64 → 128 → 256 → 512 canais
Global Average Pooling	vetor de 512
Dropout 0,2 + Linear	512 → 7 logits
Softmax	7 probabilidades

Em coral: cabeça nova (7 classes). O resto vem do ImageNet. 11,2 M parâmetros, todos treináveis.

Item	Baseline
Entrada → saída	[B, 3, 224, 224] → [B, 7]
Função de perda	entropia cruzada ponderada por classe (inverso da frequência; NV 0,045 … DF 2,9)
Otimizador	AdamW
Taxa de aprendizagem	3×10^{-4}, decaimento cosseno até ~0
Tamanho do batch	32
Número de épocas	25 — salva a época de maior macro-F1 na validação (época 19)
Regularização	weight decay 10^{-4}, dropout 0,2 e aumento de dados
Custo	AMD RX 9060 XT: ~17 s por época, 8 min no total

Dois experimentos controlados: uma mudança por vez

Experimento 1 — focal loss

O QUE MUDOU

Perda: entropia cruzada ponderada → focal loss (gama = 2, mesmos pesos de classe).

HIPÓTESE

Reduzir o peso dos exemplos fáceis (a maioria NV) melhora as classes raras e o macro-F1.

RESULTADO NA VALIDAÇÃO (EXPERIMENTO VS BASELINE)

macro-F1	0,700 vs 0,708	−0,008
acurácia balanceada	0,716 vs 0,694	+0,023
revocação MEL	0,584 vs 0,566	+0,018

CONCLUSÃO E DECISÃO

Hipótese não confirmada no macro-F1. As diferenças são menores que a oscilação do próprio baseline entre épocas (±0,02–0,04): empate técnico. Mantém-se a entropia cruzada, mais simples.

Experimento 2 — treino do zero

O QUE MUDOU

Inicialização: pesos do ImageNet → pesos aleatórios (sem transferência).

HIPÓTESE

Com ~7 mil imagens de treino, a transferência de aprendizado supera o treino do zero com folga.

RESULTADO NA VALIDAÇÃO (EXPERIMENTO VS BASELINE)

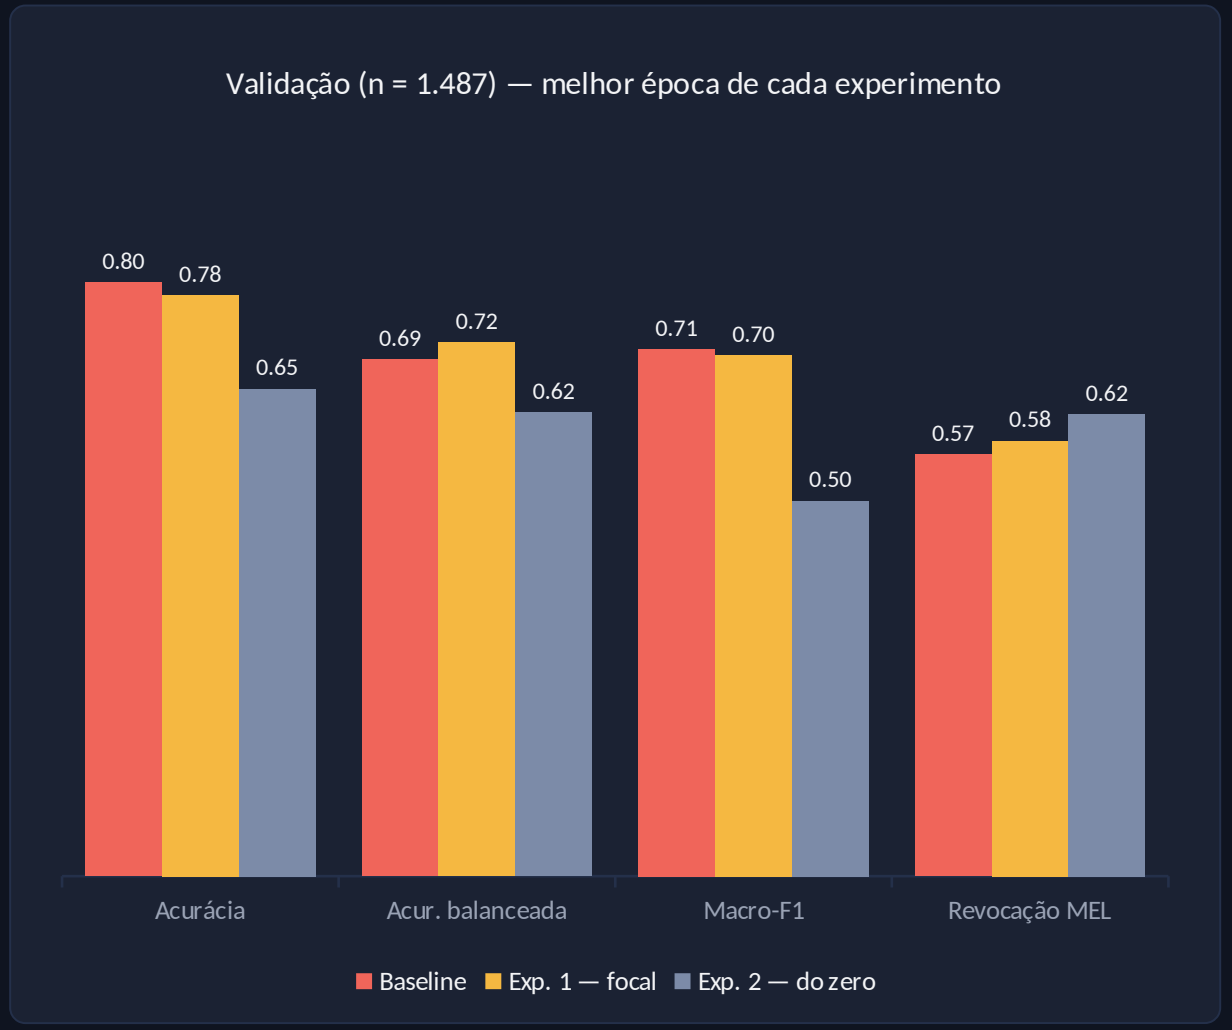
macro-F1	0,504 vs 0,708	−0,204
acurácia	0,654 vs 0,797	−0,143
F1 de DF	0,22 vs 0,69	−0,47

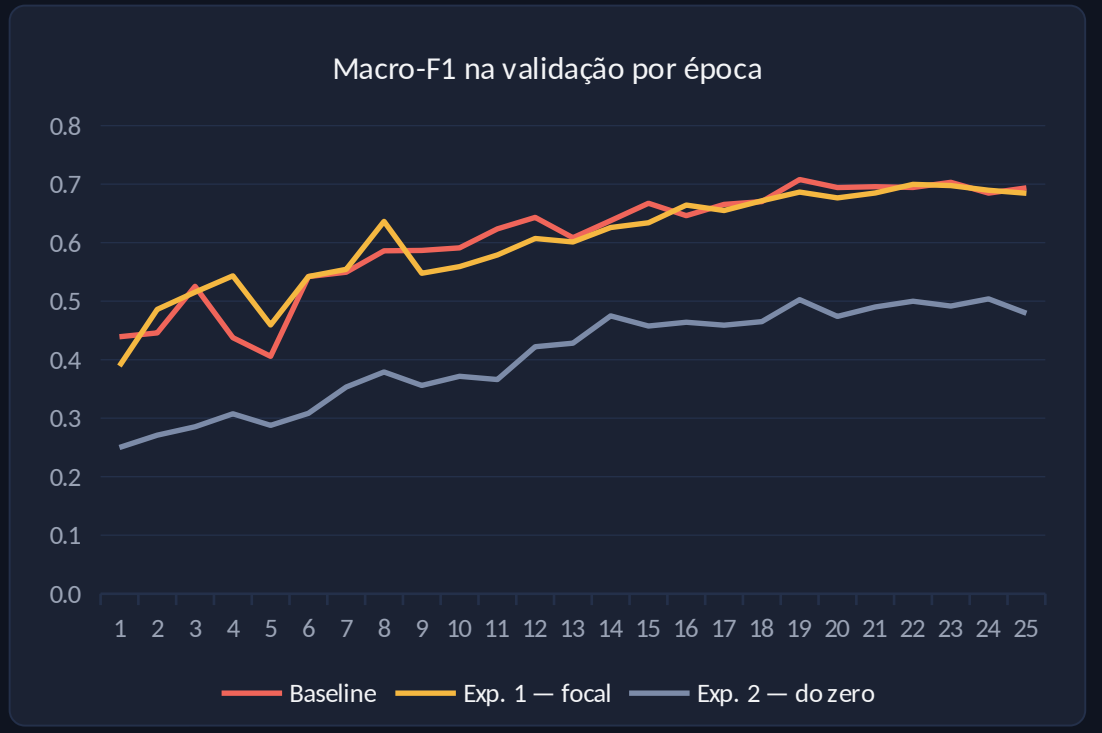
CONCLUSÃO E DECISÃO

Hipótese confirmada. Sem o ImageNet a rede não aprende bem as classes raras em 25 épocas. Transferência mantida.

Controle: mesmo split, seed 42, aumento de dados, otimizador, taxa de aprendizagem, batch e 25 épocas. A comparação usa só a validação.

Na validação o baseline lidera; treinar do zero perde 0,20 de macro-F1





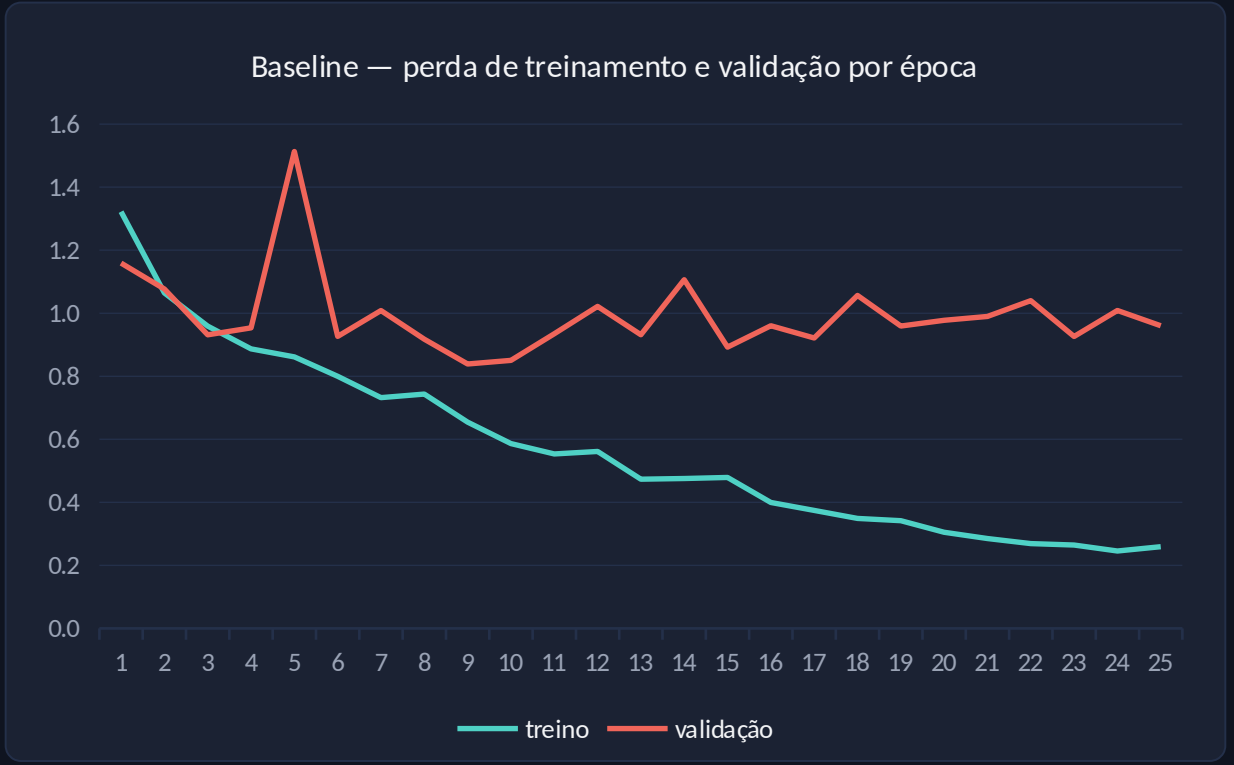
Leitura: baseline e focal loss andam juntos e oscilam ±0,02–0,04 entre épocas — a diferença de 0,008 está dentro desse ruído (1 seed). O treino do zero fica abaixo em todas as épocas.

Modelo final: baseline, estável também no teste externo

POR QUE O BASELINE

Critério definido antes de olhar o teste: maior macro-F1 na validação. Baseline 0,708 > focal 0,700 > do zero 0,504. Como baseline e focal empatam tecnicamente, a opção mais simples também favorece o baseline.

Métrica	Teste interno	Teste oficial
n	1.511	1.512
Macro-F1	**0,699**	**0,699**
Acurácia	0,795	0,785
Acurácia balanceada	0,733	0,707
Precisão macro	0,681	0,698
Revocação macro	0,733	0,707
Revocação MEL	0,713	0,667
Precisão MEL	0,455	0,487



Curvas: a perda de validação para de cair por volta da época 9, enquanto o macro-F1 segue subindo até a 19. A rede continua acertando mais, mas fica confiante demais nos erros (sobreajuste da confiança).

9 • EXEMPLOS DE ACERTOS E ERROS

Os erros mais confiantes se concentram entre NV e MEL

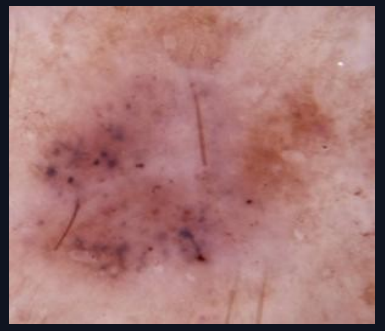
PREVISÕES CORRETAS (UMA POR CLASSE, SORTEADAS)



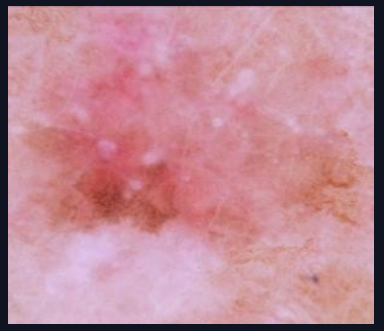
real MEL → prev. MEL
confiança 0,93



real NV → prev. NV
confiança 0,85



real BCC → prev. BCC
confiança 0,92



real AKIEC → prev. AKIEC
confiança 0,76



real BKL → prev. BKL
confiança 0,67

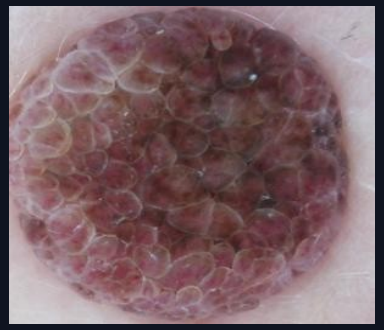


real VASC → prev. VASC
confiança 1,00

PREVISÕES INCORRETAS COM MAIOR CONFIANÇA



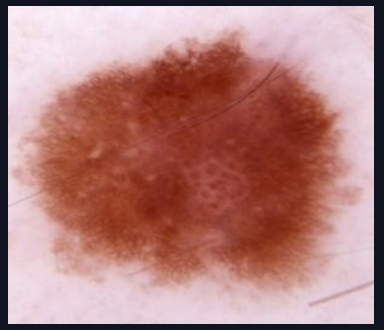
real NV → prev. MEL
confiança 1,00



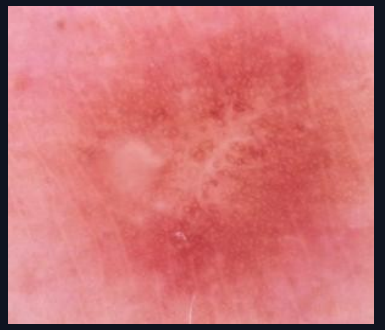
real NV → prev. MEL
confiança 0,99



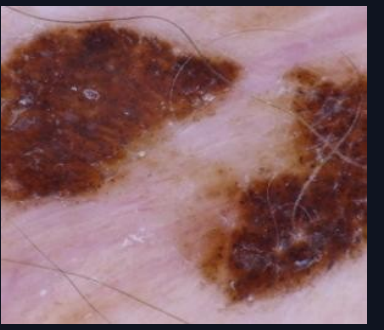
real MEL → prev. NV
confiança 0,99



real MEL → prev. NV
confiança 0,99



real DF → prev. NV
confiança 1,00



real BKL → prev. MEL
confiança 0,98

ANÁLISE DE ERROS

Onde e por que o modelo erra (teste interno, 310 erros em 1.511)

real ↓ prev. →	MEL	NV	BCC	AKIEC	BKL	DF	VASC
MEL (171)	**71%**	**17%**	·	2%	10%	·	·
NV (1032)	**12%**	**83%**	1%	1%	3%	0%	0%
BCC (65)	9%	5%	**74%**	8%	3%	2%	·
AKIEC (34)	9%	3%	3%	**68%**	**18%**	·	·
BKL (163)	10%	9%	1%	4%	**74%**	2%	·
DF (23)	4%	9%	9%	9%	**22%**	**48%**	·
VASC (23)	·	·	·	·	·	4%	**96%**

Matriz de confusão normalizada por linha: a diagonal (verde) é a revocação de cada classe; em coral, para onde vão os erros.

F1 por classe (teste): MEL 0,56 · NV 0,88 · BCC 0,77 · AKIEC 0,57 · BKL 0,69 · DF 0,51 · VASC 0,92

1

NV previsto como MEL: 120 erros (39%)

Medido: precisão de MEL 0,46. Inferido: o peso de classe de MEL é 6× o de NV e empurra a decisão para MEL — troca a favor da revocação de MEL (0,71). Teste: ajustar o limiar na validação.

2

Lesões biopsiadas são as difíceis

Medido: acurácia 0,67 com confirmação histopatológica vs 0,94 sem; em NV, 0,63 vs 0,96. Inferido: os nevos biopsiados pareciam suspeitos ao dermatologista — são casos ambíguos de verdade.

3

Vinheta: indício de atalho, não confirmado

Medido: falso MEL em 17% das não-MEL com vinheta vs 10% sem (Fisher p = 0,06; só 100 imagens com vinheta). Teste: mais dados ou mascarar os cantos.

4

O modelo sabe quando erra? Em parte

Medido: AUROC 0,84 da confiança para separar acerto de erro (0,85 no teste oficial). Confiança ≥ 0,9: 94% de acerto em 59% das imagens; < 0,5: 38%. Mas 51 erros têm confiança > 0,9.

DEMONSTRAÇÃO

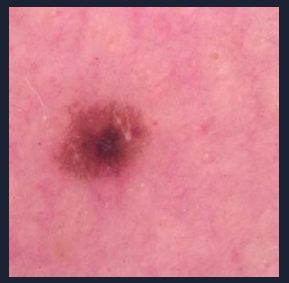
Fluxo completo em imagens novas: 5 de 7 corretas

imagem original 600×450 → pré-processamento (256 px, recorte central 224, normalização) → ResNet-18 → classe + probabilidades



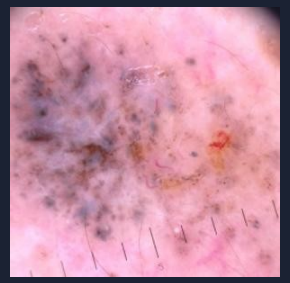
correta

real: **MEL**
previsto: **MEL**
top-3:
MEL 0,49
BKL 0,37
AKIEC 0,13



correta

real: **NV**
previsto: **NV**
top-3:
NV 0,99
DF 0,01
BKL 0,00



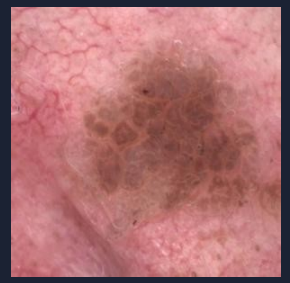
correta

real: **BCC**
previsto: **BCC**
top-3:
BCC 0,98
BKL 0,01
NV 0,01



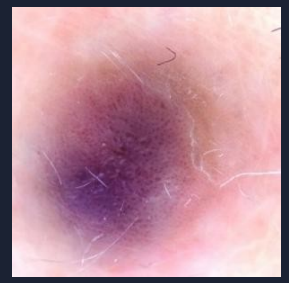
incorreta

real: **AKIEC**
previsto: **DF**
top-3:
DF 0,43
MEL 0,32
BKL 0,12



correta

real: **BKL**
previsto: **BKL**
top-3:
BKL 0,50
NV 0,47
MEL 0,03



correta

real: **DF**
previsto: **DF**
top-3:
DF 0,92
NV 0,05
VASC 0,02



incorreta

real: **VASC**
previsto: **NV**
top-3:
NV 0,93
BCC 0,06
MEL 0,01

Imagens do teste oficial ISIC 2018 (uma por classe), nunca usadas no treino nem na escolha do modelo. `python scripts/demo.py` ou `--images caminho.jpg`

Acerta 79%, erra entre NV e MEL e sabe em parte quando erra

RESPOSTA À PERGUNTA

- **Quando acerta:** 79% no teste interno e 78% no oficial (macro-F1 0,70 nos dois); melhor em lesões de aspecto típico — VASC 0,96 de revocação, NV sem biópsia 0,96 de acurácia.
- **Quando erra:** na fronteira NV ↔ MEL (quase metade dos erros), em lesões que exigiram biópsia (0,67) e na classe rara DF (0,48).
- **Se sabe que erra:** em parte — AUROC 0,84; com confiança ≥ 0,9 acerta 94%, mas 51 erros vêm com confiança > 0,9.

LIMITAÇÕES

- Uma única seed por configuração — sem intervalo de variação.
- Rótulo ≠ verdade clínica: só 53% confirmados por biópsia.
- População pouco diversa e sem fototipo — não generalizar.
- Probabilidades não calibradas (51 erros com confiança > 0,9).

FOI SATISFATÓRIO? — DEPENDE PARA QUEM

- **Para o objetivo acadêmico:** sim — baseline sólido, experimentos controlados e resultado estável fora da amostra.
- **Para uso clínico:** não — a precisão de MEL é 0,46: mais da metade dos alertas de melanoma são falsos.
- **Aprendizado:** transferência de aprendizado foi decisiva (+0,20 de macro-F1); a focal loss não ajudou; com 1 seed, diferenças abaixo de ~0,03 não sustentam decisão.

EVOLUÇÕES

- Repetir cada experimento com 3–5 seeds e reportar média ± desvio.
- Ajustar o limiar de decisão por classe na validação (custo NV → MEL).
- Testar arquiteturas maiores (EfficientNet, ResNet-50) e resolução acima de 224 px.
- Calibrar as probabilidades (temperature scaling) e investigar o atalho por vinheta.