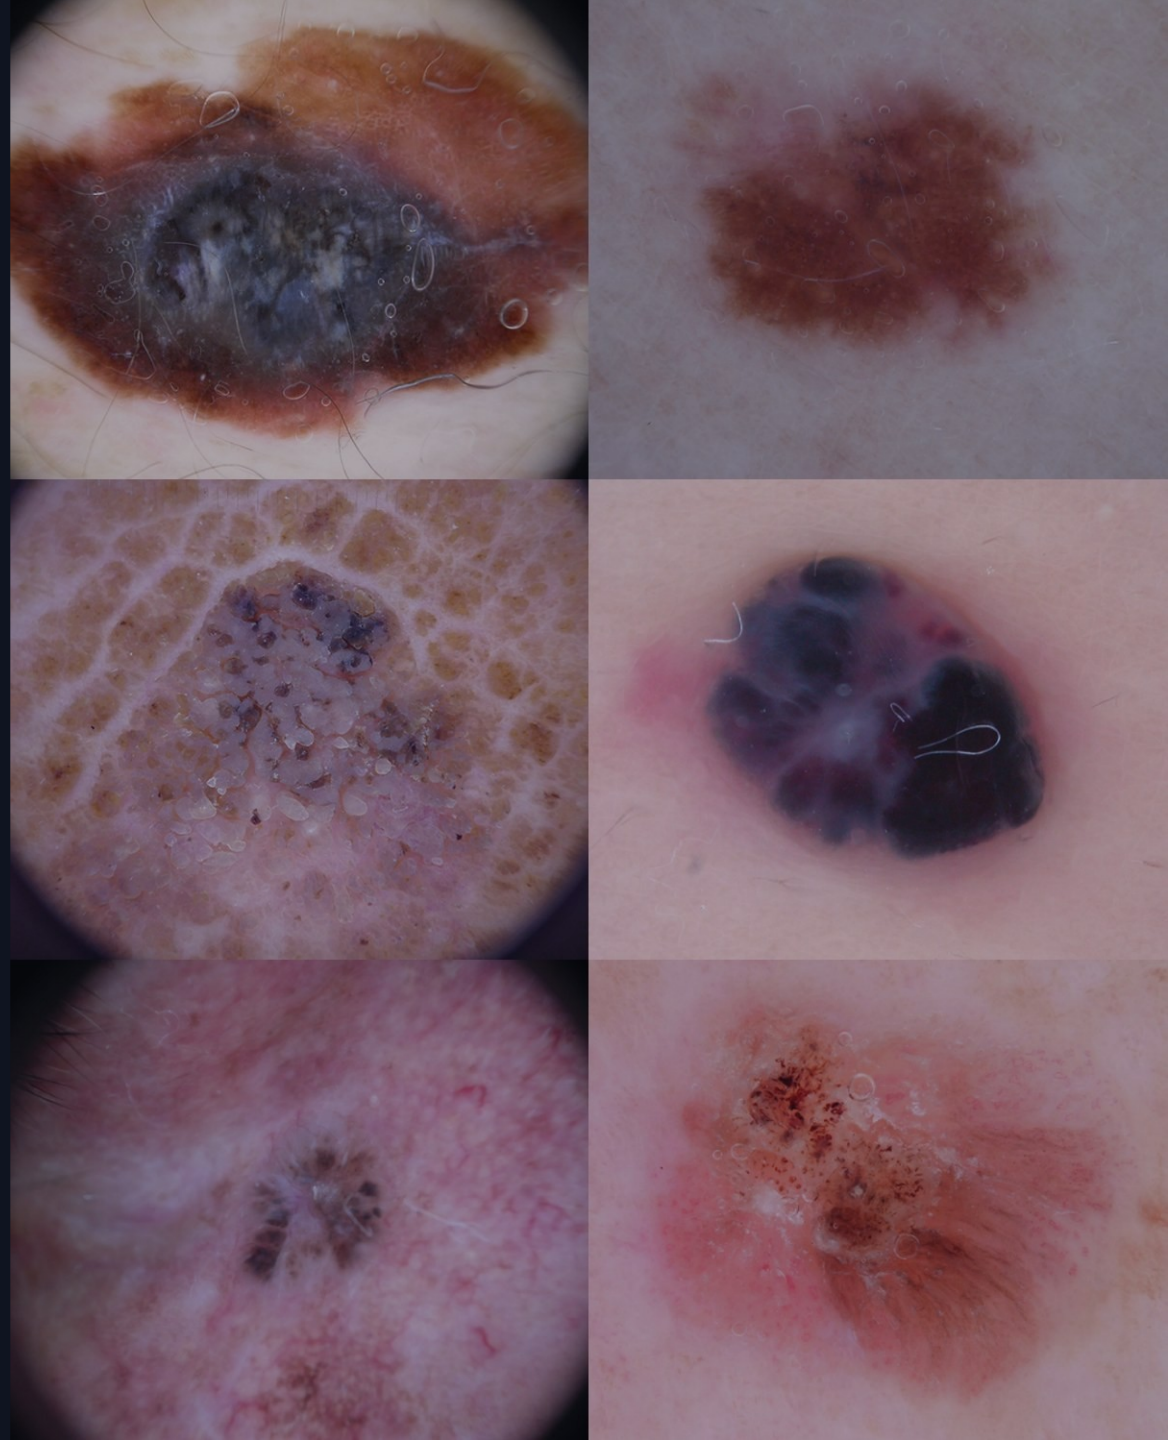
PROJETO FINAL • TEMA 3 • ENTREGA 1 (PROPOSTA)

Analisar lesões de pele com incerteza

Segmentar, classificar, explicar e sinalizar quando o modelo não deve ser confiado — com o ISIC 2018.

Valmir Carlos Cerutti Neto
Ciência de Dados e IA — IBMEC-BH
Visão Computacional e Redes Neurais • 2º sem. 2026 • 18/09/2026



PROBLEMA E MOTIVAÇÃO

O problema em uma frase — e o que entra e o que sai

Dada uma imagem dermatoscópica, delimitar a lesão, classificá-la em uma de 7 categorias, mostrar quais regiões sustentaram a decisão e sinalizar quando o modelo não deve ser confiado.

ENTRADA

- Imagem RGB dermatoscópica (JPG)
- Sem metadados na inferência — idade, sexo e local só entram na análise de erro
- Fonte: ISIC 2018 (Tasks 1 e 3)

SAÍDAS

1. **Máscara da lesão**
   segmentação binária do contorno
2. **Classe + probabilidades**
   MEL, NV, BCC, AKIEC, BKL, DF, VASC
3. **Mapa de atenção**
   Grad-CAM sobre a imagem
4. **Sinal de incerteza**
   confiança calibrada, abstenção e flag OOD

Limite ético. Sistema educacional: não substitui avaliação clínica. Vieses, incerteza e limitações fazem parte do relatório. A pergunta central é: *quando o modelo acerta, quando erra e se ele sabe que está errando?*

DADOS

Dataset: ISIC 2018 — origem, licença e organização

2.594
imagens com máscara (Task 1) • CC-0

10.015
imagens rotuladas, 7 classes (Task 3 = HAM10000) • CC BY-NC

1.512
imagens no teste oficial do desafio, com rótulo

7.470
lesões únicas — 1.956 têm 2 a 6 imagens

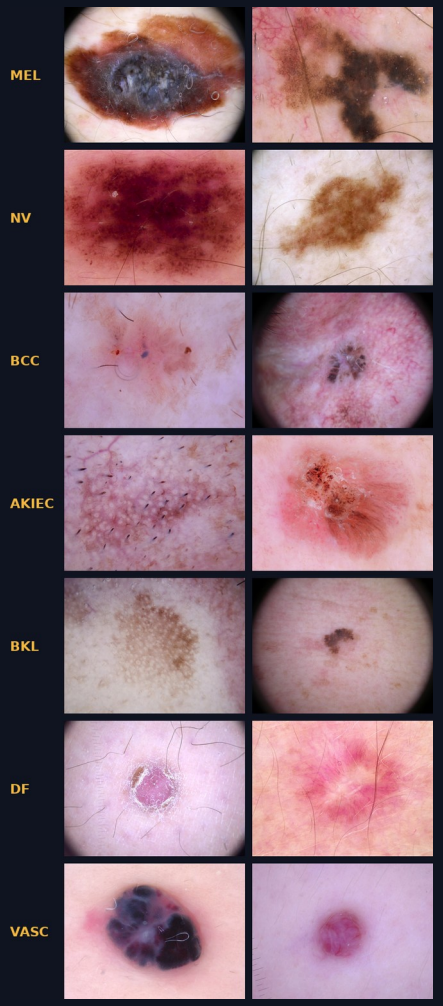


ORGANIZAÇÃO E RÓTULOS (medido no notebook)

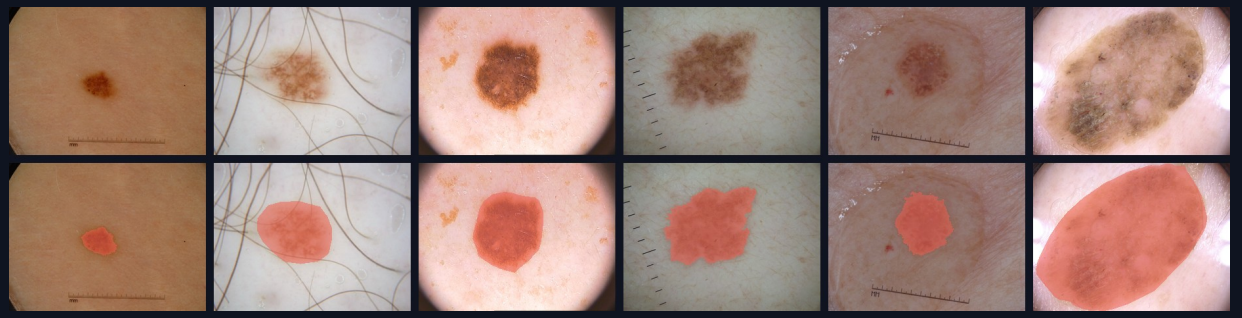
- Task 1: JPG + PNG binário por imagem; 0 pares faltando; resolução varia de 576×542 a 6708×4479 px
- Task 3: todas 600×450 px; rótulo one-hot em CSV; arquivo suplementar com lesion_id e tipo de confirmação
- Metadados HAM10000: idade (57 faltantes), sexo (54% M / 45% F), 15 localizações anatômicas
- Task 1 e Task 3 não compartilham nenhum ID — são conjuntos disjuntos
- Rótulo por histopatologia em 53% — mas 100% em MEL, BCC e AKIEC e só 37% em NV

EXPLORAÇÃO INICIAL

O que os dados mostram antes de qualquer modelo



Task 3 — 2 amostras por classe



Task 1: imagem (cima) e máscara (baixo). Réguas, pelos, vinheta e bolhas aparecem em 6 amostras aleatórias.

- **Vinheta correlaciona com a classe —** cantos escuros em 14,9% das MEL vs 3,1% das NV (amostra de 1.000). Atalho possível para a rede.
- **Lesão pequena e, às vezes, maior que o campo —** área mediana = 12,7% da imagem; 12,5% das máscaras tocam a borda.
- **Distribuição do teste oficial ≈ treino —** NV 60% vs 67%; BKL 14% vs 11%. Serve como avaliação externa.
- **Metadados permitem subgrupos —** sexo, faixa etária e 15 localizações — face concentra AKIEC (113) e BCC (101).

MEDIDO NO NOTEBOOK

600×450
resolução única da Task 3

576 a 6708 px
largura na Task 1 — exige redimensionar

58×
NV / DF

53%
rótulos por biópsia (histo)

1.956
lesões com >1 imagem

AVALIAÇÃO

Tarefas e métricas candidatas

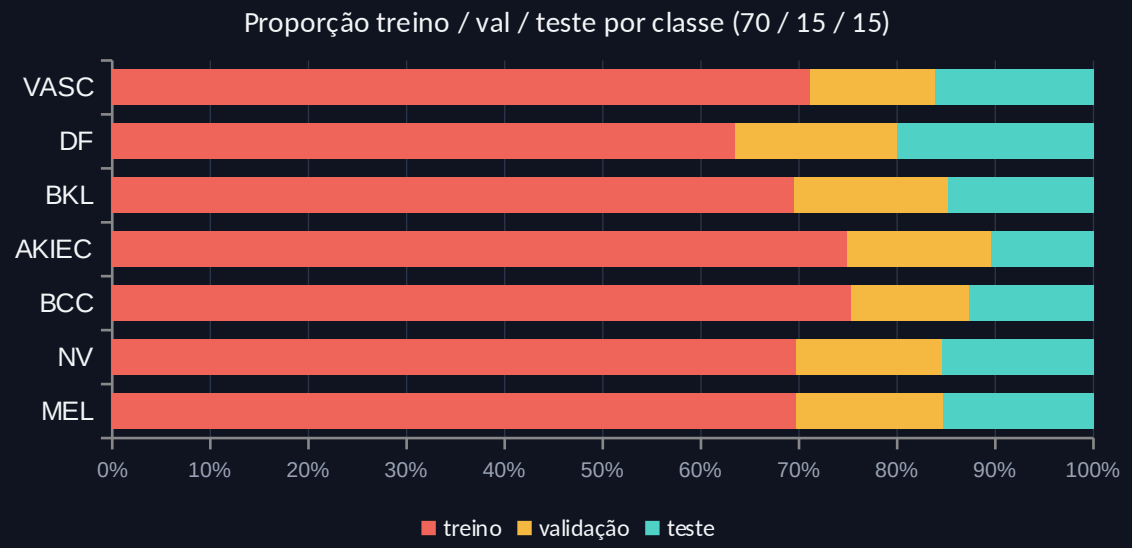
Tarefa	Métrica principal	Por quê	Meta inicial
Segmentar a lesão	Dice e IoU (média por imagem)	Mede contorno; IoU penaliza mais os erros grandes. Reportar também casos que tocam a borda.	Dice ≥ 0,85 (U-Net pré-treinada, literatura ISIC 2018)
Classificar em 7 classes	macro-F1 + AUC e Recall de MEL	Macro-F1 pesa DF e VASC como NV; Recall de MEL é a classe prioritária (falso negativo custa mais).	macro-F1 ≥ 0,70; Recall MEL ≥ 0,75
Calibração / incerteza	ECE e Brier Score	Confiança de 90% deve acertar 90%. Base para limiar de abstenção.	ECE ≤ 0,05 após temperature scaling
Fora da distribuição	AUROC de detecção OOD (in vs out)	Entropia / energia da saída separa dermatoscopia de imagens fora do domínio (câmera comum, outros objetos).	AUROC ≥ 0,90 em conjunto OOD sintético
Explicabilidade	Grad-CAM + inspeção qualitativa	Verifica se a atenção cai na lesão ou em artefatos (régua, vinheta). Sem métrica única — galeria de falhas.	≥ 80% dos acertos com atenção dentro da máscara

Análise obrigatória em todos os experimentos: desempenho por classe, por artefato de aquisição (vinheta, régua, pelo) e por subgrupo dos metadados (sexo, faixa etária, localização) — sem extrapolar além do que os metadados permitem. As metas iniciais são hipóteses a validar na M3, não compromissos.

MÉTODO

Divisão dos dados e plano: baseline, uma hipótese por vez

HIPÓTESE DE SPLIT (já implementada: data/splits/split_v1.csv)



- Agrupado por lesion_id (StratifiedGroupKFold, seed 42): 0 lesões em mais de um split — sem vazamento
- Estratificado por classe: MEL fica em 11,1 / 11,2 / 11,3%
- Task 1 divide por imagem com a mesma seed (1.811 / 384 / 399)
- Teste oficial do desafio (1.512) reservado como avaliação externa — nunca usado para escolher nada

PLANO DE EXPERIMENTOS

M2 • 09/10 — **Pipeline de dados**
redimensionamento, augmentations documentadas, auditoria de artefatos, split versionado

M3 • 23/10 — **Baseline de classificação**
ResNet-50 / EfficientNet-B0 ImageNet, fine-tuning completo, cross-entropy, 224 px. Curvas, tempo, memória, erros por classe

M4 • 06/11 — **Segmentação + 1 hipótese**
U-Net com encoder pré-treinado (Dice+BCE). Experimento: perda focal / pesos de classe vs. baseline, mesmo split e métricas

Final • 12/11 — **Incerteza e demo**
temperature scaling, limiar de abstenção, OOD por energia, Grad-CAM, galeria de falhas, inferência em imagens novas

RISCOS

Três riscos iniciais e como reduzi-los

1 Rede aprende o artefato, não a lesão

Vinheta em 14,9% das MEL vs 3,1% das NV; réguas e pelos frequentes. Um classificador pode acertar MEL olhando o canto preto.

PLANO DE REDUÇÃO

- Grad-CAM em todos os acertos de MEL: atenção dentro da máscara?
- Métricas separadas para imagens com/sem vinheta
- Augmentation de recorte circular e teste 'imagem inteira vs. recorte pela máscara'

2 Desbalanceamento de 58× esconde as classes raras

DF tem 115 imagens; 23 no teste. Acurácia global de 67% se obtém prevendo sempre NV. Um erro em DF muda o F1 da classe em pontos.

PLANO DE REDUÇÃO

- macro-F1 como métrica de decisão, nunca acurácia
- Experimento comparativo de perda focal / pesos de classe
- Intervalo de confiança por bootstrap nas classes pequenas

3 Rótulo ≠ verdade: só 53% têm biópsia

100% de MEL/BCC/AKIEC foram biopsiadas; 63% das NV foram confirmadas por follow-up ou consenso. O modelo aprende a concordar com o dermatologista, não com a patologia.

PLANO DE REDUÇÃO

- Reportar desempenho separado por tipo de confirmação
- Linguagem do relatório: 'concordância com rótulo', não 'diagnóstico'
- Teste oficial do ISIC como segunda opinião externa